

Proyecto de Investigación 2

Buscador Semántico Simple utilizando Representación Vectorial de Texto

Curso: Álgebra Lineal para la Computación

Introducción

Actualmente, los motores de búsqueda modernos no solamente comparan palabras exactas, sino que también intentan comprender el significado y la relación semántica entre los textos. Este tipo de tecnología es fundamental en sistemas como buscadores web, asistentes virtuales, sistemas de recomendación y aplicaciones de inteligencia artificial.

Una de las ideas fundamentales detrás de estos sistemas consiste en representar palabras, frases o documentos como vectores dentro de espacios de alta dimensión. Gracias al álgebra lineal, es posible medir similitud, encontrar relaciones entre documentos y recuperar información relevante utilizando operaciones vectoriales.

En este proyecto investigarán cómo construir un buscador semántico simple utilizando representaciones vectoriales de texto y medidas de similitud basadas en álgebra lineal.

Objetivos

Al finalizar el proyecto, el grupo deberá ser capaz de:

- Representar textos mediante vectores.
- Comprender el concepto de similitud semántica.
- Aplicar operaciones vectoriales sobre datos textuales.
- Implementar un buscador semántico básico.
- Analizar resultados utilizando métricas de similitud.
- Utilizar Python y bibliotecas científicas para procesamiento de texto.

I. Marco Teórico

1. Explique cómo pueden representarse palabras o documentos utilizando vectores.

Su explicación debe incluir:

- espacios vectoriales,
 - representación numérica de texto,
 - interpretación geométrica,
 - dimensión de un espacio vectorial textual.
2. Explique qué es la similitud coseno y cómo se utiliza para comparar textos.
Incluya la fórmula:

$$\cos(\theta) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}$$

e interprete geométricamente su significado.

3. Desarrolle un ejemplo matemático simple utilizando dos vectores asociados a documentos.

El ejemplo debe incluir:

- representación vectorial,
- cálculo de producto punto,
- cálculo de norma,
- cálculo de similitud coseno,
- interpretación del resultado.

II. Representación de documentos

1. Explique cómo puede construirse una matriz documento-término.

Considere:

- frecuencia de palabras,
- representación matricial,
- filas y columnas de la matriz,
- sparsidad de los datos.

2. Seleccione un conjunto de documentos o textos breves y construya una matriz documento-término utilizando Python.

Muestre:

- textos utilizados,
- vocabulario generado,
- matriz obtenida,
- dimensiones de la matriz.

III. Implementación computacional

A). Implementación

1. Explique cómo el álgebra lineal permite comparar documentos mediante operaciones vectoriales para la recuperación de información.
2. Implemente un programa en Python que:
 - a) cargue documentos o textos,
 - b) convierta los textos en vectores,
 - c) calcule similitudes entre documentos,
 - d) permita realizar búsquedas mediante consultas simples,
 - e) entregue los documentos más similares a la consulta.
3. Utilice el programa implementado y realice múltiples búsquedas utilizando distintas consultas para comparar los resultados obtenidos.

Analice:

- documentos recuperados,
- similitudes calculadas,
- calidad de las recomendaciones.

B). Análisis

1. Analice cómo afecta el tamaño del vocabulario a la representación vectorial y al desempeño del buscador.
2. Explique las ventajas y limitaciones de utilizar la similitud coseno para comparar textos.
3. Represente gráficamente los resultados obtenidos en su implementación. Puede visualizar:
 - similitudes entre documentos,
 - frecuencia de términos,
 - relaciones entre consultas y documentos.

Para ello, puede utilizar herramientas como:

- mapas de calor,
- gráficos de dispersión,
- reducción dimensional (opcional).

IV. Reflexión y conclusiones

1. Discuta las ventajas y limitaciones de implementar un buscador semántico simple basado únicamente en la frecuencia de términos.
2. Explique qué aplicaciones modernas de computación utilizan representación vectorial y similitud semántica. Por ejemplo:
 - motores de búsqueda,
 - sistemas de recomendación,
 - chatbots,
 - inteligencia artificial,
 - modelos de lenguaje.

V. Anexos

Indicar elementos utilizados:

1. Lenguaje de programación.
2. Bibliotecas.
3. Código documentado y organizado.
4. Bibliografía.

Instrucciones generales

- Forme equipos de trabajo de 4 integrantes.
- A cada grupo se le encomendará **uno** de los problemas relacionados a los siguientes temas:
 1. Compresión de Imágenes utilizando SVD,
 2. Buscador semántico simple,
 3. PCA para visualizar datos,
 4. Mini motor 3D,
 5. PageRank,
 6. Sistema de recomendación.
- El informe escrito y la presentación deben subirse a la plataforma, en el espacio que se dispondrá para ello, a más tardar el 23 de junio de 2026 a las 11:59h.
- La presentación tendrá una duración de entre 15 a 20 minutos, más 5 minutos de preguntas. Las preguntas se realizarán de manera aleatorio a cualquier integrante del grupo.
- La presentación debe incluir:
 - breve introducción,
 - fundamentos matemáticos,
 - funcionamiento del programa,
 - análisis de resultados.
- Se espera un trabajo riguroso, original y con enfoque ingenieril. Todos los resultados deben ser interpretados y discutidos críticamente. El plagio o copia entre grupos, o bien, copia directa desde una inteligencia artificial, será motivo de anulación del proyecto, o de severos descuentos de puntaje.

Criterios de evaluación

Criterio	Porcentaje
Informe	
Marco teórico y comprensión matemática	15 %
Implementación computacional	15 %
Análisis experimental	15 %
Organización y coherencia	5 %
Presentación	
Comprensión de los aspectos teóricos	15 %
Utilización y calidad de los recursos audiovisuales	5 %
Claridad de la presentación	15 %
Respuestas a las preguntas	15 %